Documento de Comprensión del Problema

Opción A — Ventas cruzadas con datos climáticos

Grupo: grupo10_data_science

1. Contexto

Una cadena de locales comerciales registra diariamente sus ventas a nivel de ítem y sucursal, incluyendo la jerarquía comercial del producto (sección, subsección, categoría y marca). En paralelo, existen registros meteorológicos diarios de temperatura para distintas estaciones distribuidas geográficamente. Ambas fuentes cubren un período común de tres años continuos (2019–2021), lo que permite explorar si las condiciones climáticas se relacionan con variaciones en el comportamiento de compra de los clientes, más allá de los factores de calendario habituales (fines de semana, fin de mes, feriados).

Este análisis resulta relevante para el negocio porque, de existir un efecto climático identificable, la cadena podría anticipar variaciones de demanda por sección o categoría (por ejemplo, sustitución entre bebidas frías y calientes) y ajustar reposición, promociones o gestión de inventario en función del pronóstico meteorológico.

2. Pregunta de investigación

¿En qué medida las condiciones meteorológicas diarias explican la variación en la cantidad de unidades vendidas por local, y en qué secciones o categorías se evidencian mayores efectos de ventas cruzadas o sustitución al aislar factores de calendario?

3. Objetivo general

Analizar en qué medida las condiciones meteorológicas diarias explican la variación en la cantidad de unidades vendidas por local, identificando patrones de venta cruzada o sustitución entre categorías cuando cambian las condiciones climáticas, y controlando el efecto de variables de calendario.

4. Objetivos específicos

- OE1 — Diagnosticar la calidad, estructura y granularidad de los datos de ventas y de meteorología disponibles (perfilado y evaluación de calidad de datos).
- OE2 — Integrar los datos de clima y ventas en un único dataset, cruzado por fecha y por estación meteorológica asignada a cada local.
- OE3 — Caracterizar, mediante análisis exploratorio univariado, temporal y bivariado, la relación entre la temperatura, las variables de calendario y la cantidad de unidades vendidas.
- OE4 — Identificar las secciones o categorías de producto que muestran mayor sensibilidad a los cambios de temperatura, como evidencia preliminar de sustitución o venta cruzada.
- OE5 — Formular hipótesis verificables para la fase de modelado e inferencia estadística (Fase 2), que permitan aislar el efecto climático del efecto de calendario.

5. Justificación

La combinación del registro transaccional detallado con mediciones meteorológicas locales es indispensable para evaluar si las oscilaciones de demanda son atribuibles al clima o a factores de

calendario. La disponibilidad de niveles jerárquicos de producto (sección, subsección, categoría, marca) permite además evaluar efectos de venta cruzada o sustitución —por ejemplo, una caída en bebidas calientes acompañada de un aumento en bebidas frías durante días calurosos— que no serían visibles analizando el total de ventas de forma agregada. Por último, la cobertura geográfica de las estaciones meteorológicas frente a la de los locales comerciales garantiza una señal climática representativa para cada punto de venta, dando viabilidad técnica al análisis propuesto.

6. Alcance

Esta primera fase (Fase 1 de CRISP-DM) comprende la comprensión del problema, la comprensión y preparación de los datos, y el análisis exploratorio (EDA) sobre el conjunto de datos completo —sin muestreo— correspondiente al período 2019–2021 y a los locales y estaciones meteorológicas incluidos en las fuentes provistas.

Quedan fuera del alcance de esta fase: la construcción de modelos predictivos o explicativos formales, las pruebas de hipótesis inferenciales (correlación con significancia controlada por múltiples factores simultáneos) y cualquier afirmación de causalidad entre clima y ventas. Los resultados de esta fase son de carácter descriptivo y exploratorio, y sirven como base para la Fase 2 del proyecto, en la que se abordará el modelado estadístico.