Informe – Fase 1 CRISP-DM

Comprensión, Preparación y Análisis Exploratorio de Datos

Proyecto: Opción A — Ventas cruzadas con datos climáticos

Grupo: grupo10_data_science

Pregunta de investigación: ¿En qué medida las condiciones meteorológicas diarias explican la variación en la cantidad de unidades vendidas por local, y en qué secciones o categorías se evidencian mayores efectos de ventas cruzadas o sustitución al aislar factores de calendario?

Etapa 1 — Perfilado de Datos

Volumen y granularidad

- Ventas (df_ventas): 9.447.662 registros transaccionales individuales a nivel de ítem/sucursal.
- Meteorología (df_meteorologia): 660 registros tabulares correspondientes a 20 estaciones meteorológicas a lo largo de 36 meses (2019–2021).

Cardinalidad de atributos

- Ubicaciones: 20 estaciones meteorológicas georreferenciadas por departamento.
- Jerarquía de producto: múltiples secciones (desc_secciones), subsecciones, categorías y marcas asociadas a cada transacción.

Distribución térmica

- Rango: mínimo de 3,90 °C y máximo de 36,70 °C.
- Media de 22,75 °C y mediana de 23,60 °C, mostrando un comportamiento típico de clima subtropical con estacionalidad marcada.

Etapa 2 — Evaluación de Calidad de los Datos

Dimensión de calidad	Criterio de evaluación	Hallazgo en el dataset	Acción correctiva recomendada
Completitud	Registros faltantes numéricos	380 valores nulos (NaN) en las columnas Día29, Día30 y Día31.	Nulos estructurales por meses de menos de 31 días; se eliminan automáticamente al convertir a serie temporal continua.
Integridad	Presencia de caracteres no numéricos	18 celdas registradas con asteriscos (*) en la matriz de días de temperatura.	Reemplazo por NaN y posterior imputación por interpolación lineal o promedio de la estación.
Consistencia de tipos	Formato de variables	fecha_vta e identificadores de sucursal parseados como objeto (object).	Conversión explícita de fecha_vta a datetime64 para posibilitar el join temporal.
Coherencia relacional	Alineación espacial-temporal	Cobertura temporal de 3 años continuos (2019–2021) en ambas fuentes de datos.	Cruce por fecha y asignación de estación cercana por local.

Etapa 3 — Justificación de la Selección de Datos

Relevancia para el negocio: la combinación del registro transaccional detallado con mediciones meteorológicas locales es indispensable para probar estadísticamente si las oscilaciones de demanda son causadas por el clima o por factores de calendario (fines de semana, cobrar a fin de mes, feriados).

Suficiencia y granularidad: la presencia de niveles jerárquicos (desc_secciones, desc_categoria) permite evaluar el efecto de venta cruzada o sustitución (ej. caída en bebidas calientes y aumento en bebidas frías durante días calurosos).

Viabilidad técnica: las 20 estaciones meteorológicas cubren la distribución geográfica de los locales comerciales, garantizando una señal climática representativa y geolocalizada para cada punto de venta.

Etapa 4 — Bitácora de Decisiones: Preparación de los Datos

Paso	Acción	Justificación / Resultado
Limpieza de caracteres no numéricos	Se removieron los asteriscos (*) presentes en 18 celdas de las columnas Día01–Día31, convirtiéndolos a valores nulos (NaN).	Los asteriscos impedían el tratamiento numérico de la temperatura; convertirlos a NaN permite su posterior imputación.
Reestructuración (melt)	Se transformó el dataset meteorológico de formato ancho (una fila por estación-mes) a formato largo (una fila por fecha-estación).	Formato necesario para cruzar el clima con las ventas por fecha, según el objetivo específico 2.
Eliminación de nulos estructurales	Se descartaron los registros de fechas inexistentes (ej. 30 de febrero), origen de los 380 nulos identificados.	No representan datos faltantes reales, sino un artefacto de la matriz de 31 columnas fijas.
Imputación de temperatura	Los nulos restantes (por asteriscos) se completaron por interpolación lineal dentro de cada estación, con la media de la estación como respaldo en los extremos.	Preserva la continuidad de la serie temporal sin introducir sesgos relevantes, dado el bajo volumen afectado (18 casos).
Conversión de tipos	fecha_vta se convirtió de texto (object) a datetime64.	Requisito técnico para poder cruzar por fecha con el dataset climático.
Asignación local → estación	Se asignó cada local a una estación meteorológica mediante un mapeo manual (diccionario).	El dataset no incluye información geográfica real de los locales; se adoptó como supuesto simplificador, documentado para su revisión.
Cruce de datasets (merge)	Se unieron df_ventas y df_meteo_largo por fecha y estación asignada.	Resultado: 9.447.662 registros antes y después del cruce, sin pérdida ni duplicación, y 0 filas sin temperatura asignada.
Variables de calendario	Se agregaron día de semana, fin de semana, mes, año y feriado (Paraguay).	Permiten aislar los efectos de calendario del efecto climático, según la metodología (punto d).

Resultado: el dataset final (df_final) integra ventas, clima y variables de calendario en un único DataFrame, listo para la etapa de análisis exploratorio y modelado.

Etapa 5 — Análisis Exploratorio de Datos (EDA)

Sobre df_final (9,4 millones de registros, sin muestreo) se implementó un notebook de EDA en Python (pandas, numpy, matplotlib, seaborn, scipy), optimizado para trabajar con el volumen completo: tipos de datos livianos (category, float32, int8) desde la lectura, y agregaciones previas a cada visualización para no graficar el detalle transaccional completo.

5.1 Análisis univariado

- Cantidad vendida: estadísticos de tendencia central y dispersión (media, mediana, moda, desvío estándar, percentiles, rango intercuartílico, coeficiente de variación), histograma y boxplot.
- Temperatura: estadísticos descriptivos, distribución e identificación de valores extremos, histograma y boxplot.
- Variables categóricas (desc_secciones, desc_categoria, local): frecuencias absolutas y relativas, gráficos de barras.

5.2 Análisis temporal

- Serie temporal de ventas agregadas por fecha (2019–2021).
- Comportamiento mensual y anual de las ventas.
- Comparación entre días laborales y fines de semana.

5.3 Análisis bivariado

- Temperatura vs. ventas: agregación diaria, diagrama de dispersión, correlación de Pearson y de Spearman.
- Clima vs. ventas: se documentó que el dataset integrado solo dispone de temperatura como variable meteorológica (no hay variable de precipitación disponible en las fuentes provistas).
- Categorías vs. temperatura: agrupación en bandas climáticas (frío, templado, caluroso) por terciles, y comparación de ventas promedio por sección/categoría para detectar posibles patrones de sustitución o venta cruzada.

5.4 Matriz de correlación

Se construyó un heatmap de correlación (Pearson) sobre variables agregadas por día (cantidad total, temperatura promedio, mes, día de semana, fin de semana, feriado), con el objetivo de visualizar en conjunto la relación entre el clima, el calendario y las ventas.

Nota metodológica: las interpretaciones de cada gráfico y estadístico se generan de forma dinámica dentro del propio notebook, a partir de los valores efectivamente calculados sobre el dataset real al momento de ejecutarlo, para evitar anticipar resultados no verificados.

A partir de este análisis se plantearon las siguientes hipótesis para la fase inferencial:

- H1: Las ventas promedio de la sección más sensible al clima presentan diferencias estadísticamente significativas según el grupo climático (frío/templado/caluroso), controlando por local.
- H2: Existe una asociación significativa entre la temperatura diaria y la cantidad total vendida, incluso controlando por variables de calendario (fin de semana, feriado, mes).

- H3: El efecto de la temperatura sobre las ventas difiere significativamente entre secciones comerciales, evidenciando sustitución (ej. bebidas frías vs. calientes) más que un efecto homogéneo.
- H4: El día de la semana (particularmente el fin de semana) modera la magnitud del efecto climático sobre las ventas.
- H5: El efecto climático sobre las ventas varía por local, en función de la estación meteorológica asignada.

Conclusión

El dataset final integrado (df_final) presenta una calidad adecuada para el análisis: los problemas detectados en el perfilado inicial (nulos estructurales por meses de menos de 31 días y celdas con asteriscos) fueron identificados, justificados y resueltos durante la preparación de los datos, sin pérdida ni duplicación de registros tras el cruce entre ventas y clima.

La combinación de datos transaccionales de alta granularidad con mediciones meteorológicas geolocalizadas resulta adecuada para abordar la pregunta de investigación planteada, ya que permite tanto observar la relación agregada entre temperatura y ventas como descomponerla por sección y categoría de producto, donde se espera que los efectos de sustitución sean más visibles.

El análisis exploratorio (Etapa 5) provee la base descriptiva y las primeras hipótesis (H1–H5) necesarias para avanzar hacia la fase de modelado, en la que se buscará aislar estadísticamente el efecto climático del efecto de las variables de calendario y del local, evitando así conclusiones causales prematuras a partir de correlaciones simples.

Como limitación general de esta fase, se destaca la ausencia de una variable de precipitación en las fuentes de datos disponibles, así como el uso de un mapeo manual (supuesto simplificador) entre locales y estaciones meteorológicas ante la falta de coordenadas reales de los puntos de venta; ambos aspectos quedan documentados para su eventual revisión en iteraciones futuras del proyecto.